

INSTITUTO FEDERAL CATARINENSE

NATALIA KELIM THIEL

**ALGORITMO GENÉTICO:
IMPLEMENTAÇÃO DO JOGO 2048**

**RIO DO SUL
OUTUBRO/2018**

INTRODUÇÃO

Inspirados na evolução, algoritmos genéticos são um conjunto de modelos computacionais que incorporam uma potencial solução à um problema específico numa estrutura cromossômica, aplicando operadores de seleção, reprodução e mutação. O alfabeto, que são os elementos na representação do cromossomo, podem ser de três formas: binária, inteira ou real. Cada cromossomo contém um conjunto de gene, estruturado pelo formato do alfabeto, que será passado por várias gerações a fim de otimizar e melhorar os resultados.

Inicialmente é gerada uma população de cromossomos aleatória para compor a geração zero. Então é aplicada uma avaliação, onde um fitness é gerado com base nas características do cromossomo. Quanto maior o fitness, melhor é este indivíduo. O método de seleção é utilizado na tentativa de juntar pares com os melhores fitness para reprodução. A reprodução combina os pares, resultando em dois filhos com suas características. Por fim é aplicado uma taxa de mutação a cada gene, que geralmente não passa de 0,5%, para simular a mutação natural.

Com este processo as gerações seguintes se tornam mais otimizadas e tendem a ser melhores. Entretanto cada execução pode trazer um resultado diferente, visto a aleatoriedade de seleção e possível mutação.

PROBLEMA

Este trabalho busca um algoritmo genético para resolver o jogo 2048, que tem como objetivo juntar pares de números iguais a fim de os soma e obter o maior número. A tela do jogo consiste em uma tabela, onde são possíveis os movimentos para cima, baixo, esquerda e direita. A cada movimento surge um novo número, que pode ser 2 ou 4, em um espaço vazio aleatório. A Figura 1 mostra uma representação do jogo.




Figura 1 - Jogo 2048

CROMOSSOMOS E GENES

Para este problema foi escolhida a uma modelagem onde cada gene representa um movimento e um cromossomo representa uma sequência de movimentos. Os movimentos são representados em inteiros de 0 a 3, sendo esquerda, cima, direita e baixo respectivamente.

FITNESS

Para representar o fitness foi utilizado o score do jogo, ou seja, a melhor pontuação. A pontuação é uma soma de todas as junções no jogo, por exemplo: juntar 4+4 em um movimento acrescentará 8 no score.

OPERADORES GENÉTICOS

Neste trabalho foram aplicados os operadores de seleção, reprodução e mutação. Para a seleção foi utilizado o método roleta viciada, onde os cromossomos são dispostos em uma roleta tendo maior porcentagem dela de acordo com o fitness. Na reprodução foi utilizado o método de crossover com dois cortes, onde são escolhidos aleatoriamente dois pontos de corte para mesclar os genes dos pais. A mutação foi utilizada com uma porcentagem de 0,5%.

TESTES

Os testes a seguir foram aplicados a fim de mostrar os resultados acerca do algoritmo genético criado para resolução do jogo 2048.

População	Movimentos	Mutação	Gerações	Fitness	Número
20	15	0,5%	10	112	32
20	20	0,5%	10	292	64
20	50	0,5%	10	464	64
4	50	0,5%	10	436	64
20	100	0,5%	10	1160	128

20	300	0,5%	10	2548	256
20	500	0,5%	10	2496	256
20	1000	0,5%	10	2250	256
50	300	0,5%	10	2956	256
50	300	1%	10	3016	256
50	300	2%	10	2544	256
20	300	0,5%	20	2768	256
15	300	0,5%	100	3428	256
26	300	0,5%	100	4164	512

CÓDIGO DOCUMENTADO

O código, desenvolvido em Java, foi separado em duas partes, a primeira é a resolução de algoritmos genéticos para alfabetos inteiros genéricos e depois é implementada no jogo 2048. A classe *Chromosome*, mostrada na Figura 2, representa um cromossomo, contendo um identificador único, uma lista de genes inteira, a geração onde ela pertence e seu fitness.

```

5      /**
6       * Represents a gene list
7       * Each gene starts in 0 and ends in geneLimit
8       * @author Natalia Kelim Thiel
9       * @version 1.0.0
10     */
11     public class Chromosome {
12
13         private final int id;
14         private final int[] geneList;
15         private final Generation generation;
16         private int fitness;
17
18         /**
19          * Constructor with a existent gene list
20          * @param generation
21          * @param geneList
22          */
23         public Chromosome(Generation generation, int[] geneList) {
24             id = NextId.nextId();
25             this.generation = generation;
26             this.geneList = geneList;
27             updateFitness();
28         }
29
30         /**
31          * Update the fitness value
32          */
33         public void updateFitness() { fitness = geneList.length; }
34     }
35
36

```

Figura 2 - Classe Chromosome

O método *updateFitness* da linha 33 deve ser sobrescrito de acordo com a necessidade. A classe *Chromosome* também contém o método *mutation* que realiza a mutação em cada gene do cromossomo, mostrado na Figura 3. Na linha 42 são percorridos todos os genes e verificados se devem ser mutados de acordo com sua chance (linhas 43 e 44). A mutação ocorre na linha 50.

```

37     /**
38      * Do the mutation
39      */
40     public void mutation() {
41         ThreadLocalRandom r = ThreadLocalRandom.current();
42         for (int i = 0; i < geneList.length; i++) {
43             double chance = r.nextDouble();
44             if (chance >= generation.getMutation()) {
45                 continue;
46             }
47
48             int mut;
49             do {
50                 mut = r.nextInt(generation.getGeneLimit());
51             } while (mut == geneList[i]);
52             geneList[i] = mut;
53         }
54     }

```

Figura 3 - Mutação

As gerações são representadas na classe *Generation*, Figura 4, que contém um id único, o limite do alfabeto (*geneLimit*), a taxa de mutação (*mutation*), o tamanho do cromossomo (*chromosomeSize*), a lista de cromossomos (*chromosomeList*) e a soma de todos os fitness (*totalFitness*). Esta classe também utiliza da característica *generics* do java, onde *T* pode ser qualquer classe que estenda *Chromosome*.

```
13  /**
14   * Represents the individuals of a generation
15   * @author Natalia Kelim Thiel
16   * @version 1.0.0
17   */
18  public class Generation <T extends Chromosome> {
19
20      private final int id;
21      private final int geneLimit;
22      private final double mutation;
23      private final int chromosomeSize;
24      private List<T> chromosomeList;
25      private int totalFitness;
26
27      /**
28       * Constructor with a new empty chromosome list
29       * @param geneLimit
30       * @param mutation
31       */
32      public Generation(int geneLimit, double mutation, int chromosomeSize) {
33          assert geneLimit > 0;
34          assert mutation >= 0 && mutation <= 1;
35          assert chromosomeSize > 0;
36
37          id = NextId.nextId();
38          this.geneLimit = geneLimit;
39          this.mutation = mutation;
40          this.chromosomeSize = chromosomeSize;
41          chromosomeList = new ArrayList<>();
42          totalFitness = 0;
43      }
```

Figura 4 - Classe Generation

O método para criação de uma nova geração a partir da anterior é o *nextGeneration*, onde é realizada a busca por pares (linha 73), aplicada a reprodução (linha 79 e 80) e a aplicada a mutação (linha 83). A Figura 5 mostra este método. O parâmetro *Class* é utilizado para criar instâncias de uma classe específica, podendo ser a classe *Chromosome* ou uma extensão.

```

68  /**
69   * Next generation
70   * @return
71   */
72  public Generation nextGeneration(Class classObject) {
73      List<Pair> parents = getParents();
74      Generation next = new Generation(geneLimit, mutation, chromosomeSize);
75      // Get the new children
76      parents.stream().parallel().forEach(parent ->
77      {
78          try {
79              List<Chromosome> chromosomes = chrossover(
80                  (T) parent.getKey(), (T) parent.getValue(), classObject);
81              next.addAll(chromosomes);
82              for (Chromosome chromosome : chromosomes) {
83                  chromosome.mutation();
84              }
85          } catch (NoSuchMethodException e) {
86              e.printStackTrace();
87          } catch (IllegalAccessException e) {
88              e.printStackTrace();
89          } catch (InvocationTargetException e) {
90              e.printStackTrace();
91          } catch (InstantiationException e) {
92              e.printStackTrace();
93          }
94      }
95      );
96
97      return next;
98  }

```

Figura 5 - Método nextGeneration

A seleção de pares é mostrada na Figura 6, onde são gerados pares (linha 153) com o método de roleta viciada até serem válidos, ou seja, não se repetirem.


```

145  /**
146   * Random parents to build a next generation
147   * @return
148   */
149  protected List<Pair> getParents() {
150      updateTotalFitness();
151      List<Pair> parents = new ArrayList<>();
152      do {
153          Pair newParent = new Pair(getRouletteRandom(), getRouletteRandom());
154          if (isNewParentValid(newParent, parents)) {
155              parents.add(newParent);
156          }
157      } while (parents.size() * 2 < chromosomeList.size());
158
159      return parents;
160  }
161
162  /**
163   * Find a chromosome by roulette method
164   * @return
165   */
166  protected Chromosome getRouletteRandom() {
167      double p = ThreadLocalRandom.current().nextDouble();
168
169      Chromosome parent = chromosomeList.get(chromosomeList.size() - 1);
170      double total = 0;
171      for (int i = 0; i < chromosomeList.size(); i++) {
172          Chromosome c = chromosomeList.get(i);
173          double value = c.getFitness() / (double) totalFitness;
174          total += value;
175          if (total >= p) {
176              parent = c;
177              break;
178          }
179      }
180      return parent;
181  }

```

Figura 6 - Método `getParents` e `getRouletteRandom`

A Figura 7 representa o operador de reprodução, crossover de 2 cortes. São gerados cortes aleatórios (linha 113), ordenados (linha 115) e aplicados (linhas 127 a 133).

```

100  /**
101   * Make two children with the parents feature
102   * @param mom
103   * @param dad
104   * @return
105   */
106  protected List<Chromosome> chrossover(Chromosome mom, Chromosome dad, Class classObject)
107  {
108      ThreadLocalRandom r = ThreadLocalRandom.current();
109      int[] children1 = new int[chromosomeSize];
110      int[] children2 = new int[chromosomeSize];
111      int nCuts = 2;
112      int[] cut = new int[nCuts];
113      for (int i = 0; i < nCuts; i++) {
114          cut[i] = r.nextInt(origin: 1, bound: mom.size() - 2);
115      }
116      Arrays.sort(cut);
117
118      for (int i = -1; i < nCuts; i++) {
119          int initial = 0;
120          int limit = mom.size();
121          if (i != -1) {
122              initial = cut[i];
123          }
124          if (i != nCuts - 1) {
125              limit = cut[i + 1];
126          }
127          for (int c = initial; c < limit; c++) {
128              if (i % 2 == 0) {
129                  children1[c] = mom.get(c);
130                  children2[c] = dad.get(c);
131              } else {
132                  children2[c] = mom.get(c);
133                  children1[c] = dad.get(c);
134              }
135          }
136      }
137  }

```

Figura 7 - Método chrossover

Para testar e exemplificar este conjunto de classes, a Figura 8 mostra a programação.

```

14  class GenerationTest {
15
16      private static final int GENERATION_LENGTH = 10;
17      private static final int CHROMOSOME_LENGTH = 6;
18      private static final int GENE_LIMIT = 4;
19      private static final double GENE_MUTATION = 0.005;
20      private static Generation generation;
21
22      @BeforeAll
23      static void setUp() throws NoSuchMethodException, InstantiationException,
24          IllegalAccessException, InvocationTargetException {
25          generation = new Generation(GENE_LIMIT, GENE_MUTATION,
26              CHROMOSOME_LENGTH, GENERATION_LENGTH, Chromosome.class);
27          System.out.println(generation);
28      }
29
30      @Test
31      void nextGeneration() {
32          Generation next = generation.nextGeneration(Chromosome.class);
33          System.out.println(next);
34      }
35  }

```

Figura 8 - Testes de Geração

O resultado do teste é mostrado na Figura 9.

```
Generation 0 (F: 0, L: 4)
#1 [ 1 2 1 2 1 1 ]
#2 [ 3 1 3 1 3 3 ]
#3 [ 1 3 2 2 1 3 ]
#4 [ 0 0 3 1 2 1 ]
#5 [ 0 1 2 3 3 1 ]
#6 [ 1 0 0 0 2 3 ]
#7 [ 0 0 2 0 1 0 ]
#8 [ 1 2 1 2 0 0 ]
#9 [ 0 3 3 0 3 3 ]
#10 [ 2 3 3 3 2 0 ]
Generation 1 (F: 60, L: 4)
#11 [ 3 3 3 1 3 3 ]
#12 [ 1 1 2 2 1 3 ]
#13 [ 0 3 3 0 3 3 ]
#14 [ 1 3 2 2 1 3 ]
#15 [ 1 1 1 2 0 0 ]
#16 [ 0 2 2 3 3 1 ]
#17 [ 0 3 2 3 3 1 ]
#18 [ 1 1 2 2 1 3 ]
#19 [ 3 0 3 1 3 3 ]
#20 [ 0 1 3 1 2 1 ]
```

Figura 9 - Resultado dos Testes de Geração

A classe Game implementa a lógica do jogo 2048 e também estende a classe *Chromosome*, mostrada na Figura 10. Nela são armazenados o array do jogo, o score e o número de movimentos executados.

```

12  /**
13   * Represents the game board with the movements
14   * @author Natalia Kelim Thiel
15   * @version 1.0.0
16   */
17  public class Game extends Chromosome {
18
19      public static final int WIDTH = 4;
20      public static final int HEIGHT = 4;
21      private final SimpleIntegerProperty[][] board;
22      private SimpleIntegerProperty score;
23      private SimpleIntegerProperty movements;
24      private boolean running = true;
25
26      /**
27       * Constructor with the super params
28       * @param generation
29       * @param geneList
30       */
31      public Game(Generation generation, int[] geneList) {
32          super(generation, geneList);
33          board = new SimpleIntegerProperty[HEIGHT][WIDTH];
34          for (int i = 0; i < HEIGHT; i++) {
35              for (int j = 0; j < WIDTH; j++) {
36                  board[i][j] = new SimpleIntegerProperty( initialValue: 0);
37              }
38          }
39          score = new SimpleIntegerProperty( initialValue: 0);
40          movements = new SimpleIntegerProperty( initialValue: 0);
41          nextNumber();
42      }

```

Figura 10 - Classe Game

Para interface gráfica foi utilizado JavaFX. A Figura 11 mostra o resultado final de uma geração.

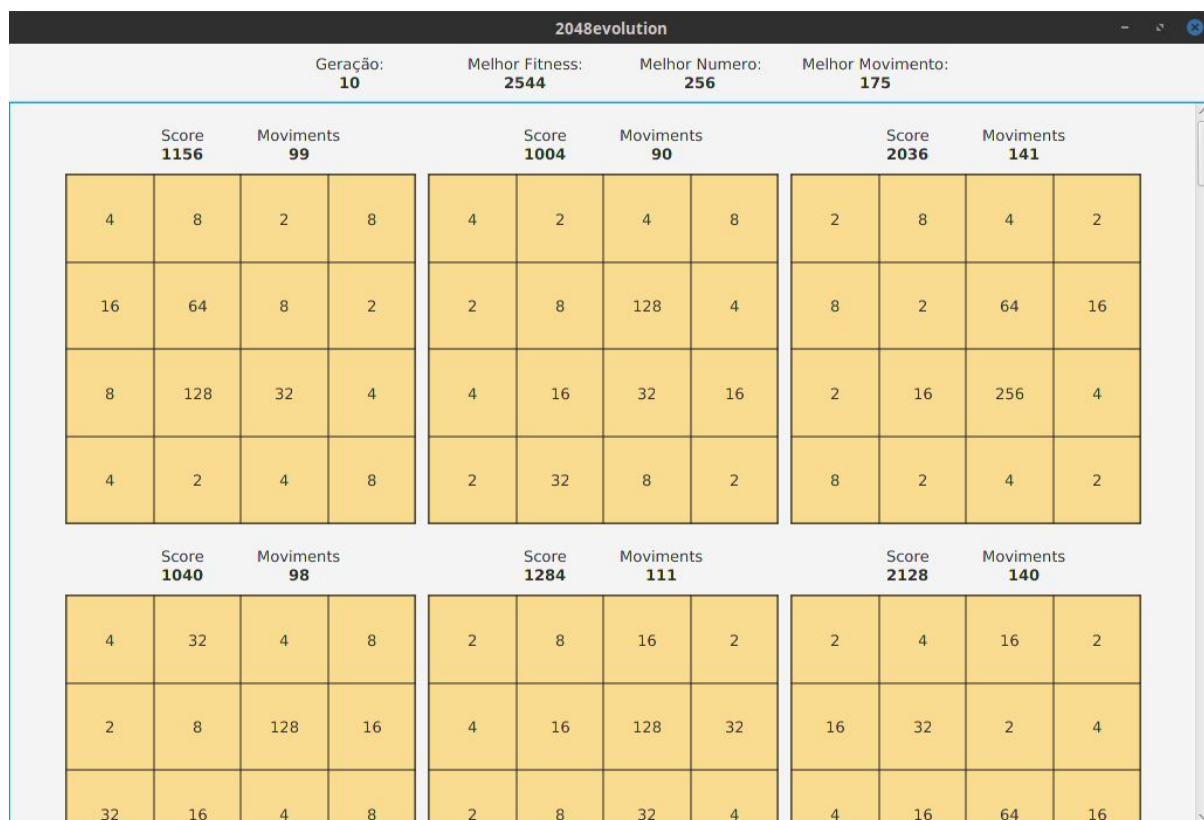


Figura 11 - Interface Gráfica

CONCLUSÃO

Mesmo com poucas gerações é possível visualizar uma conversão grande, entretanto não foi possível obter o valor 2048 em todos os testes, sendo o maior valor obtido em número 512 e score 4164. A implementação dos algoritmos genéticos se mostrou simples e seus resultados satisfatórios, sendo que 300 movimentos são considerados o ideal pois os valores acima não mostram mudança. Entretanto para uma melhor aplicação, como trabalhos futuros, implementar mais métodos de seleção e reprodução, a fim de comparar os resultados.